INSTITUTO FEDERAL
Pernambuco

Diagnóstico Fitossanitário em Folhas de Cana-de-Açúcar via CNN Embarcada com TinyML, Pipeline Assíncrono Dual-Core no ESP32-S3 e Co-Simulação HIL com VANT

Phytosanitary Diagnosis in Sugarcane Leaves via Embedded CNN with TinyML, Dual-Core Asynchronous Pipeline on ESP32-S3, and UAV HIL Co-Simulation

Victor Giuliano de Freitas Silva
victor.giuliano@ufpe.br
Orientador
Email do orientador

RESUMO

A cultura da cana-de-açúcar (*Saccharum officinarum* L.) constitui um pilar histórico, econômico e social de Pernambuco e do Brasil, mas sofre perdas severas de produtividade decorrentes de patógenos foliares de rápida dispersão, como o Carvão (*Sporisorium scitamineum*) e a Ferrugem Marrom (*Puccinia melanocephala*). A ausência de conectividade em áreas rurais inviabiliza diagnósticos dependentes de nuvem, enquanto o uso direto de microcontroladores de baixo custo acoplados a Veículos Aéreos Não Tripulados (VANTs) esbarra em dois gargalos críticos: o borrão de movimento (*motion blur*) causado por sensores de imagem com obturador rolante (*rolling shutter*) e a degradação radiométrica provocada por algoritmos elementares de subamostragem espacial em cores de 16 bits (RGB565). Este trabalho apresenta o projeto, a modelagem matemática, a implementação em firmware nativo (ESP-IDF/FreeRTOS) e a validação experimental de um sistema autônomo de visão computacional em borda (*TinyML*) embarcado no SoC dual-core ESP32-S3 para classificação em tempo real de 11 classes fitossanitárias da cana-de-açúcar. Propõe-se uma arquitetura paralela híbrida em dois níveis aliada ao algoritmo de decodificação JPEG em 24 bits (RGB8888) com filtro anti-aliasing *Box-Averaging* assistido por tabela de busca (*Look-Up Table* – LUT) e alocação de *scratch buffers* na memória SRAM interna para aceleração vetorial SIMD Xtensa LX7. Adicionalmente, realizou-se uma auditoria por hash criptográfico MD5 no conjunto de treinamento que identificou e erradicou 214 duplicatas cruzadas entre classes, elevando a acurácia no hardware físico para 89,82% no lote limpo de validação e fazendo a detecção do Carvão saltar de 4,0% para 84,0%. As otimizações de pré-processamento e paralelismo reduziram o tempo de decodificação em 90,1% (de $1.032,4$ ms para $102,7$ ms) e a latência de inferência em 63,5% (de $777,4$ ms para $283,4$ ms), alcançando paridade matemática exata (PSNR $= \infty$ dB) com o pipeline de treinamento em ponto flutuante. Uma avaliação exaustiva sobre 9.269 imagens revelou e quantificou o fenômeno de Deslocamento de Domínio (*Domain Shift*) frente a sensores heterogêneos. Por fim, validou-se a estratégia de controle autônomo de Parada

Instituto Federal de Pernambuco. Campus Paulista. Curso de Tecnólogo em Análise e Desenvolvimento de Sistemas. novembro de 2026.

Amostral Sistemática (*Pause-and-Classify*) em bancada de Co-Simulação *Hardware-in-the-Loop* (HIL) via protocolo MAVLink sobre um talhão georreferenciado de 55 waypoints, obtendo ciclo médio de parada de $1.130,1$ ms por ponto (38,9% abaixo do teto de projeto) e gerando automaticamente camadas SIG (GeoJSON/QGIS) e mapas de calor interativos de focos epidêmicos.

Palavras-chave: TinyML. Cana-de-açúcar. ESP32-S3. Visão Computacional Embarcada. Agricultura 4.0. MAVLink.

ABSTRACT

Sugarcane (*Saccharum officinarum* L.) is a historical, economic, and social pillar of Pernambuco and Brazil, yet it suffers severe yield losses caused by rapidly dispersing foliar pathogens such as Smut (*Sporisorium scitamineum*) and Brown Rust (*Puccinia melanocephala*). The lack of connectivity in rural areas renders cloud-dependent diagnostics unfeasible, while deploying low-cost microcontrollers aboard Unmanned Aerial Vehicles (UAVs) faces two critical bottlenecks: motion blur induced by rolling-shutter image sensors and radiometric degradation caused by naive spatial downsampling in 16-bit color space (RGB565). This paper presents the design, mathematical modeling, native firmware implementation (ESP-IDF/FreeRTOS), and experimental validation of an autonomous edge computer vision system (*TinyML*) embedded on the dual-core ESP32-S3 SoC for real-time classification of 11 sugarcane phytosanitary classes. A two-level hybrid parallel architecture is proposed alongside a 24-bit JPEG decoding algorithm (RGB8888) featuring Look-Up Table (LUT)-assisted Box-Averaging anti-aliasing and internal SRAM scratch buffer allocation for Xtensa LX7 SIMD vector acceleration. Furthermore, an MD5 cryptographic hash audit of the training dataset identified and eliminated 214 cross-class exact duplicates, raising on-chip accuracy to 89.82% on the clean validation benchmark and boosting Smut detection from 4.0% to 84.0%. Preprocessing and parallelism optimizations reduced decoding time by 90.1% (from $1,032.4$ ms to 102.7 ms) and neural inference latency by 63.5% (from 777.4 ms to 283.4 ms), achieving exact mathematical parity (PSNR $= \infty$ dB) with the floating-point training pipeline. An exhaustive evaluation across 9,269 images characterized and quantified Domain Shift effects across heterogeneous camera sensors. Finally, the autonomous *Pause-and-Classify* flight control strategy was validated on a MAVLink Hardware-in-the-Loop (HIL) co-simulation bench across a 55-waypoint georeferenced sugarcane plot, achieving an average hover cycle of $1,130.1$ ms per sampling point (38.9% below the design ceiling) and automatically synthesizing GIS layers (GeoJSON/QGIS) and interactive epidemic heatmaps.

Keywords: TinyML. Sugarcane. ESP32-S3. Embedded Computer Vision. Agriculture 4.0. MAVLink.

---

1 INTRODUÇÃO

A cana-de-açúcar (*Saccharum officinarum* L.) constitui um dos pilares históricos, econômicos e socioculturais de Pernambuco desde o período colonial. Implantada nas Capitanias Hereditárias no século XVI, a capitania de Pernambuco destacou-se como uma das mais prósperas do Brasil colonial, com o açúcar representando a principal riqueza e o motor da ocupação efetiva do litoral e da Zona da Mata nordestina (Freyre, 2004). Os engenhos de açúcar moldaram a sociedade, a economia e o território pernambucano por séculos, posicionando o estado como centro dinâmico da vida social, política e econômica do Nordeste (Freyre, 2004; Mello, 2007). Ainda hoje, apesar da diversificação econômica estadual, a cultura canavieira mantém relevância estratégica: Pernambuco figura entre os principais produtores do Nordeste, tendo processado cerca de 11,6 milhões de toneladas de cana na safra 2024/25, contribuindo expressivamente para o setor sucroenergético nacional, que responde por parcela vital do Produto Interno Bruto (PIB) agrícola, produção de açúcar, etanol de primeira e segunda geração e cogeração de bioeletricidade, além da manutenção de cerca de 70 mil empregos diretos apenas no estado (Companhia Nacional de Abastecimento - CONAB, 2024; CONAB, 2025; Sindaçúcar-PE, 2024; Santos *et al.*, 2023).

No contexto contemporâneo de desafios agrícolas, marcados por mudanças climáticas, pressão fitossanitária e necessidade contínua de elevação da eficiência produtiva em pequenos, médios e grandes produtores, o monitoramento de doenças foliares nas lavouras de cana-de-açúcar assume caráter crítico. Patógenos fúngicos, bacterianos e virais — tais como o Carvão da Cana (*Sporisorium scitamineum*), a Ferrugem Marrom (*Puccinia melanocephala*), o Complexo de *Fusarium* (*Pokkah Boeng*), a Mancha Parda (*Cercospora longipes*), a Podridão de Toletes (*Ceratocystis paradoxa*) e o Vírus do Amarelinho (*Sugarcane yellow leaf virus* – SCYLV) — podem ocasionar quebras severas de produtividade entre 20% e 50% caso não sejam identificados e contidos precocemente (Mariano *et al.*, 2023; Barbedo, 2019; CONAB, 2025).

Tradicionalmente, a inspeção fitossanitária baseia-se no caminhamento técnico em campo por agrônomos e pragueiros, método laborioso, subjetivo e incapaz de cobrir a totalidade da malha produtiva em tempo hábil devido ao porte denso do dossel canavieiro (Radoglou-Grammatikis *et al.*, 2020). Embora o advento da Agricultura 4.0 e de Redes Neurais Convolucionais (CNNs) tenha impulsionado o diagnóstico automatizado por imagens (Lu *et al.*, 2022; Xu *et al.*, 2023), a grande maioria das arquiteturas propostas na literatura depende do envio contínuo de fluxos de vídeo ou fotografias de alta resolução para servidores em nuvem (*Cloud Computing*) ou exige computadores de bordo de alto custo e elevado consumo energético (como módulos NVIDIA Jetson) (Rodríguez; Santos; Oliveira, 2021). Nas zonas rurais brasileiras e, de modo particular, na agricultura familiar pernambucana, a cobertura de conectividade móvel de banda larga é intermitente ou inexistente, e o custo de aceleradores gráficos dedicados inviabiliza sua adoção em larga escala (Oliveira *et al.*, 2024; He *et al.*, 2023).

Para superar essas barreiras tecnológicas e econômicas, este trabalho desenvolve, otimiza e valida um sistema completo de visão computacional em borda baseado em aprendizado de máquina embarcado (*TinyML*) (Warden; Situnayake, 2019), executando inteiramente sobre o microcontrolador de baixo custo e ultrabaixo consumo **ESP32-S3** (Espressif Systems, 2024, 2023b). Todavia, a implantação de uma CNN ca-

paz de distinguir 11 classes fitossanitárias em um sistema embarcado acoplado a um Veículo Aéreo Não Tripulado (VANT) impõe dois desafios científicos e de engenharia fundamentais que são solucionados neste artigo:

1. **Distorção Radiométrica e Aliasing no Pré-Processamento Embarcado:** Bibliotecas convencionais de decodificação JPEG para microcontroladores operam no espaço de cor reduzido RGB565 (16 bits por pixel) e aplicam subamostragem espacial por vizinho mais próximo (*Nearest-Neighbor*) ou truncamento de ponto fixo. Demonstra-se matematicamente que essa prática viola o Teorema da Amostragem de Nyquist-Shannon (Nyquist, 1928; Shannon, 1949), introduzindo um viés sistemático de nível contínuo (Bias DC $\approx -2,90$ LSB) e destruindo as microtexturas de pústulas de ferrugem e chicotes de carvão;
2. **Borrão de Movimento (*Motion Blur*) e Contenção de Memória Externa:** Câmeras embarcadas de baixo custo empregam obturador eletrônico por rolamento (*rolling shutter*), sofrendo cisalhamento geométrico sob vibração e translação do VANT. Ademais, a execução simultânea de decodificação de imagens e inferência neural sobre a mesma memória externa (Octal PSRAM) gera severa contenção de barramento, degradando o tempo de resposta.

O objetivo geral deste trabalho consiste em projetar, implementar e validar um pipeline assíncrono multinúcleo em tempo real no SoC ESP32-S3 para o diagnóstico de 11 classes foliares de cana-de-açúcar, integrado a uma estratégia de controle de voo autônomo via protocolo MAVLink. Especificamente, as contribuições deste artigo compreendem: (i) a auditoria por hash criptográfico MD5 do conjunto de dados público e o treinamento de um modelo MobileNetV2 quantizado em 8 bits ($\mathrm{v08}$) livre de vazamento de dados (*data leakage*); (ii) a formulação do algoritmo de pré-processamento **Modo 7 (RGB8888 + Box-Averaging com LUT)**, que atinge paridade matemática exata (PSNR $= \infty$ dB) com o modelo em nuvem e reduz o tempo de decodificação em 90,1% ($102,7$ ms); (iii) uma arquitetura paralela híbrida em dois níveis no FreeRTOS combinada à alocação de *scratch buffers* na SRAM interna para instruções vetoriais SIMD, reduzindo o tempo de inferência para $283,4$ ms; (iv) uma avaliação exaustiva sobre 9.269 imagens documentando o comportamento frente ao deslocamento de domínio (*Domain Shift*); e (v) a validação em bancada de Co-Simulação *Hardware-in-the-Loop* (HIL) da máquina de estados *Pause-and-Classify* com geração automatizada de mapas de calor fitossanitários para Sistemas de Informação Geográfica (SIG/QGIS).

2 FUNDAMENTAÇÃO TEÓRICA

A fundamentação teórica desta pesquisa articula cinco domínios: a inserção da Agricultura 4.0 na realidade produtiva e familiar, a computação em borda integrada a aeronaves remotamente pilotadas via MAVLink, as arquiteturas de Redes Neurais Convolucionais eficientes, as técnicas de quantização e aceleração vetorial em *TinyML* e a teoria do processamento digital de sinais aplicada à subamostragem de imagens.

2.1 Indústria 4.0, Agricultura 4.0 e o Contexto da Agricultura Familiar

A Indústria 4.0 caracteriza-se pela fusão de sistemas ciberfísicos, Internet das Coisas (IoT), inteligência artificial e computação distribuída nos ambientes produtivos (Kagermann; Wahlster; Helbig, 2013). Na esfera agropecuária, esses preceitos originaram a Agricultura 4.0, que utiliza sensoriamento remoto, veículos autônomos e aprendizado de máquina para elevar a produtividade, otimizar o uso de insumos e mitigar impactos ambientais (Lu *et al.*, 2022; Xu *et al.*, 2023).

Não obstante, a difusão dessas inovações na agricultura familiar e em pequenas propriedades fornecedoras de cana-de-açúcar no Nordeste enfrenta entraves estruturais: restrição de capital de investimento, carência de conectividade rural e complexidade operacional de softwares proprietários (Oliveira *et al.*, 2024). Nesse cenário, dispositivos embarcados de baixíssimo custo e operação autônoma na borda democratizam o acesso à agricultura de precisão, permitindo identificar precocemente focos de patógenos e substituir a pulverização extensiva em área total pelo manejo localizado (Mariano *et al.*, 2023).

2.2 Internet das Coisas, Computação em Borda e Integração MAVLink com VANTs

A Internet das Coisas (IoT) interconecta sensores e atuadores físicos para aquisição distribuída de dados no campo (Asi; Haidine, 2014). A computação em borda (*edge computing*) desloca o processamento analítico diretamente para a fonte geradora do dado — o microcontrolador acoplado ao sensor óptico —, oferecendo quatro vantagens determinantes sobre arquiteturas baseadas em nuvem (Satyanarayanan *et al.*, 2009; Shi *et al.*, 2016; He *et al.*, 2023): (i) latência determinística compatível com controle em tempo real; (ii) independência de enlaces de telecomunicações externos; (iii) economia de largura de banda e energia de transmissão de rádio; e (iv) soberania e privacidade dos dados agronômicos.

Na inspeção aérea por VANTs, a coordenação entre o módulo de visão embarcado (*companion payload*) e a controladora de voo (como ArduPilot ou PX4) é regida pelo protocolo **MAVLink** (*Micro Air Vehicle Link*) (Koubâa *et al.*, 2019). O MAVLink define uma estrutura leve de quadros binários verificados por soma de verificação CRC-16/MCRF4XX, suportando mensagens de telemetria de posicionamento geodésico (`GLOBAL_POSITION_INT`, ID 33), atitude tridimensional (`ATTITUDE`, ID 30), sinalização de estado (`HEARTBEAT`, ID 0) e comandos de controle de navegação (`COMMAND_LONG`, ID 76), os quais permitem ao microcontrolador comandar pausas autônomas e registrar diagnósticos georreferenciados (Radoglou-Grammatikis *et al.*, 2020).

2.3 Visão Computacional e Arquitetura MobileNetV2

As Redes Neurais Convolucionais (CNNs) constituem o estado da arte na extração hierárquica de atributos visuais para classificação de patologias vegetais (Krizhevsky; Sutskever; Hinton, 2012; Goodfellow; Bengio; Courville, 2016). O aprendizado por transferência (*transfer learning*) viabiliza a adaptação de extratores pré-treinados em

grandes bases genéricas (ImageNet) para o domínio específico de lesões foliares com elevado poder de generalização (Yosinski *et al.*, 2014).

Para viabilizar a execução em sistemas embarcados restritos, A. G. Howard *et al.* (2017) propuseram a família MobileNet, substituindo a convolução espacial padrão por **Convoluções Separáveis em Profundidade** (*Depthwise Separable Convolutions*), que fatoram a filtragem em uma etapa espacial por canal (*Depthwise* 3×3) seguida de uma combinação linear pontual (*Pointwise* 1×1), reduzindo o custo computacional em até 8 a 9 vezes. A arquitetura **MobileNetV2** (Sandler *et al.*, 2018) aprimorou esse paradigma ao introduzir os **Blocos Residuais Invertidos** (*Inverted Residuals*) e os **Gargalos Lineares** (*Linear Bottlenecks*), nos quais conexões de atalho (*skip connections*) interligam tensores compactos de baixa dimensionalidade sem função de ativação não-linear na saída do gargalo, preservando a informação do espaço latente e permitindo escalonamento fino por meio do multiplicador de largura α (*width multiplier*) (Sandler *et al.*, 2018; Howard, A. *et al.*, 2019).

2.4 TinyML, Quantização Simétrica INT8 e Aceleração Vetorial SIMD no ESP32-S3

O paradigma *TinyML* abrange a compressão e execução de modelos de aprendizado profundo em microcontroladores com consumo na faixa de miliwatts e memória RAM inferior a poucos megabytes (Warden; Situnayake, 2019; Moons; Bankman; Verhelst, 2020). A técnica central para essa viabilização é a **Quantização Pós-Treinamento Inteira Completa** (*Full Integer Post-Training Quantization* – INT8) (Jacob *et al.*, 2018), que mapeia pesos e ativações em ponto flutuante de 32 bits ($r \in \mathbb{R}$) para inteiros com sinal de 8 bits ($q \in [-128, 127]$) segundo a transformação afim:

$$q = \text{clip}\left(\left\lfloor \frac{r}{S} \right\rceil + Z, -128, 127\right) \tag{1}$$

onde $S \in \mathbb{R}^+$ representa o fator de escala e $Z \in \mathbb{Z}$ o ponto zero (*zero-point*). Além de reduzir em 75% a pegada de memória do modelo, a quantização INT8 elimina operações de ponto flutuante e habilita o uso das instruções vetoriais **SIMD** (*Single Instruction, Multiple Data*) presentes na extensão de conjunto de instruções (PIE – *Processor Instruction Extensions*) dos dois núcleos Xtensa LX7 do SoC **ESP32-S3** (Espressif Systems, 2024, 2023b). Através da biblioteca otimizada em Assembly `esp-nn` (Espressif Systems, 2023a) e do interpretador TensorFlow Lite Micro (Google LLC, 2024), registradores vetoriais de 128 bits executam até 16 operações de multiplicação e acumulação (MAC) de 8 bits paralelamente por ciclo de clock.

2.5 Teoria da Amostragem Espacial e Anti-Aliasing no Pré-Processamento

Conforme o Teorema da Amostragem de Nyquist-Shannon (Nyquist, 1928; Shannon, 1949) e a teoria clássica de processamento digital de imagens (Gonzalez; Woods, 2018), a redução da resolução espacial de uma imagem discreta $I(x, y)$ de dimensões $W_0 \times H_0$ para um tensor de entrada $T(u, v)$ de dimensões $W_1 \times H_1$ (com fator de decimação $M = W_0/W_1$) exige a aplicação prévia de um filtro passa-baixas anti-aliasing com frequência de corte $\omega_c = \pi/M$.

Quando a subamostragem é realizada por seleção direta de pixels (*Nearest-Neighbor*), as altas frequências espaciais das lesões foliares dobram-se sobre o espectro de baixa frequência (*aliasing*). Em contrapartida, o filtro de **Média em Caixa** (*Box-Averaging* ou interpolação por área) integra todos os pixels pertencentes à janela projetada $\Omega(u, v)$:

$$T(u,v) = \left\lfloor \frac{1}{|\Omega(u,v)|} \sum_{(x,y)\in\Omega(u,v)} I(x,y) \right\rfloor - 128 \tag{2}$$

atuando como um filtro passa-baixas ideal no domínio espacial, suprimindo ruído de alta frequência e preservando integralmente a energia cromática média de cada região foliar.

3 METODOLOGIA

A metodologia adotada nesta pesquisa possui natureza aplicada, experimental e quantitativa, estruturada em cinco etapas: (i) especificação da plataforma de hardware e ambiente de desenvolvimento; (ii) auditoria forense do conjunto de dados e treinamento supervisionado do modelo neural; (iii) engenharia de pré-processamento radiométrico on-chip; (iv) projeto do pipeline paralelo dual-core no sistema operacional de tempo real FreeRTOS; e (v) construção da bancada de co-simulação HIL com protocolo MAVLink.

3.1 Plataforma de Hardware e Ambiente de Desenvolvimento

O sistema embarcado foi implementado sobre a placa de desenvolvimento **ESP32-S3-DevKitM-1** (Espressif Systems, 2024), equipada com o SoC Xtensa Dual-Core LX7 de 32 bits operando a 240 MHz, 512 KB de memória SRAM interna de alta velocidade, 8 MB de memória externa **Octal PSRAM DDR** (barramento de 8 linhas operando a 80 MHz com taxa de transferência de 160 MB/s), 16 MB de memória Flash Quad-SPI e transceptor sem fio IEEE 802.11 b/g/n.

O firmware foi desenvolvido utilizando a plataforma **PlatformIO** (PlatformIO Labs, 2024) integrada ao framework oficial **ESP-IDF (v5.x)** e componentes C/C++ otimizados com a diretiva de compilação `-O2`. O armazenamento do modelo neural quantizado (`model_mbnet_int8.tflite`, 624 KB) foi alocado em uma partição dedicada do sistema de arquivos tolerante a falhas **LittleFS** na memória Flash.

3.2 Conjunto de Dados, Auditoria Forense MD5 e Treinamento do Modelo `v08`

Em uma etapa preliminar exploratória, avaliou-se o subconjunto reduzido do *Sugarcane Leaf Disease Dataset* (Daphal; Koli, 2022) composto por 2.569 imagens e 5 classes utilizando a plataforma Edge Impulse (Edge Impulse Inc., 2024). Para conferir abrangência fitossanitária real de campo, expandiu-se o escopo para a base completa de **11 classes foliares** (6.748 imagens no repositório primário e 2.521 imagens em um repositório secundário de arquivo com sensores heterogêneos, totalizando **9.269 imagens**). As 11 classes contempladas pelo modelo embarcado são: *Banded Chlorosis*

(Clorose Zonada), *Brown Spot* (Mancha Parda), *BrownRust* (Ferrugem Marrom), *Dried Leaves* (Folhas Secas), *Grassy shoot* (Enfezamento / Broto Gramíneo), *Healthy Leaves* (Folhas Saudáveis), *Pokkah Boeng* (Complexo de *Fusarium*), *Sett Rot* (Podridão Abacaxi), *Viral Disease* (Viroses / Mosaico), *Yellow Leaf* (Síndrome da Folha Amarela) e *smut* (Carvão da Cana).

Durante a avaliação do modelo inicial (v07), constatou-se uma anomalia severa: embora a acurácia global aparentasse superar 82%, a sensibilidade na classe crítica *smut* (Carvão) era de apenas **4,0%** (2 acertos em 50 amostras), com 68% das folhas de Carvão sendo erroneamente classificadas como *Pokkah Boeng*. Para investigar a causa raiz, executou-se uma auditoria forense computacional calculando a assinatura criptográfica **MD5 de 128 bits** sobre o conteúdo binário de todos os arquivos do dataset primário, cujos resultados são sintetizados na Tabela 1.

Tabela 1 – Auditoria Forense por Hash MD5 e Saneamento do Dataset Primário (11 Classes)

Classe Fitossanitária	Bruto	Únicos na Pasta	Dups. Internas	Colisões Cruzadas	% Contam.	Base Limpa
Banded Chlorosis	471	418	53	105	22,3%	313
Brown Spot	1.722	1.434	288	23	1,3%	1.411
BrownRust	314	284	30	77	24,5%	207
Dried Leaves	343	271	72	23	6,7%	250
Grassy shoot	346	346	0	0	0,0%	346
Healthy Leaves	430	430	0	13	3,0%	417
Pokkah Boeng	**297**	**297**	**0**	**110**	**37,0%**	**187**
Sett Rot	652	652	0	0	0,0%	652
Viral Disease	663	635	28	90	13,6%	545
Yellow Leaf	1.194	918	276	33	2,8%	885
***smut* (Carvão)**	**316**	**316**	**0**	**140**	**44,3%**	**176**
TOTAL GERAL	**6.748**	**6.001**	**747**	**614 (306 pares)**	**9,1%**	**5.389**

A auditoria revelou que **614 arquivos (306 pares de imagens binariamente idênticas)** estavam arquivados simultaneamente sob pastas de patologias distintas, além de **747 cópias internas duplicadas**. O caso mais crítico concentrou-se entre as classes *Pokkah Boeng* e *smut*, onde **110 imagens de *Pokkah Boeng* eram cópias idênticas de *smut*** (e outras 30 fotos de *Viral Disease* duplicavam *smut*, contaminando 44,3% da classe Carvão). Matematicamente, ao submeter uma amostra duplicada x com rótulos contraditórios y_A e y_B à função de perda de Entropia Cruzada Categórica, o gradiente resultante força o vetor de probabilidades predito $p(x)$ para um ponto de sela indeciso ($p_A \approx p_B \approx 0,5$), destruindo a fronteira de decisão.

Para o treinamento da nova versão do modelo (v08), realizou-se a expurgação estrita por hash MD5 (desduplicação antes do particionamento em 70% treino, 15% validação e 15% teste), a substituição da interpolação bilinear por interpolação de área (`area`) no Keras/TensorFlow, a introdução de pesos de classe inversamente proporcionais à frequência corrigida ($w_{\text{smut}} = 3,50$ e $w_{\text{Pokkah}} = 2,80$) e o treinamento com **Perda Focal Suavizada** (*Categorical Focal Cross-Entropy*, $\gamma = 2,0$, *label smoothing* $\varepsilon = 0,05$) (Lin *et al.*, 2017) sobre a arquitetura MobileNetV2 ($\alpha = 0,75$, entrada $160 \times 160 \times 3$), seguida de quantização inteira completa INT8.

3.3 Engenharia de Pré-Processamento On-Chip: Modo 7 (RGB8888 + Box-Averaging)

No firmware original (denominado **Modo 0**), o decodificador `JPEGDEC` operava em formato RGB565 (5 bits para Vermelho, 6 para Verde e 5 para Azul) e aplicava sobrescrita de coordenadas sobre um tensor pré-zerado. Esse método truncava os 3 bits menos significativos dos canais R e B, gerando um deslocamento sistemático negativo (Bias DC $= -2,90$ LSB) e descartando cerca de 95% dos pixels das fotos de alta resolução (768×1024).

Para restaurar a fidelidade radiométrica sem penalizar a CPU, projetou-se e implementou-se no arquivo `src/image_processor.cpp` o algoritmo **Modo 7 (RGB8888 + Box-Averaging com Aceleração IDCT)**. O pipeline opera em três estágios:

1. **Escalonamento no Domínio da Frequência (Hardware IDCT Scaling):** Para imagens cuja menor dimensão exceda 640 pixels, aciona-se a flag `JPEG_SCALE_HALF` durante a Transformada Discreta do Cosseno Inversa (IDCT), reduzindo cada bloco 8×8 para 4×4 diretamente na etapa de descompressão entrópica e cortando em 75% o volume de pixels a processar;

2. **Decodificação Nativa em 24 bits (`RGB8888`):** Elimina-se a quantização intermediária de 16 bits, preservando os 8 bits originais de cada canal cromático;

3. **Acumulação em Caixa Compacta (8 Bytes) e Divisão por LUT:** Cada pixel decodificado (x, y) é acumulado na célula correspondente (u, v) de uma matriz de estruturas `BoxAccumulator` de apenas 8 bytes (`uint16_t r, g, b, count`) alocada na Octal PSRAM (200 KB). Ao final do quadro, elimina-se a instrução de divisão inteira para os 25.600 pixels do tensor (160×160) utilizando uma **Tabela de Busca de Recíprocos em Ponto Fixo Q16** ($\text{inv_lut}[c] = \lfloor 65536/c \rfloor$ para $1 \leq c < 256$):

$$q_{\text{canal}}(u, v) = ((\text{soma}_{\text{canal}} \times \text{inv_lut}[c] + 32768) \gg 16) - 128 \tag{3}$$

Essa formulação substitui 786.432 divisões inteiras por multiplicações e deslocamentos lógicos de 1 ciclo de clock, reduzindo as divisões em **99,77%**.

3.4 Arquitetura Paralela Híbrida FreeRTOS em Dois Níveis e Otimização SRAM

Para maximizar o aproveitamento dos dois núcleos Xtensa LX7 do ESP32-S3, estruturou-se uma arquitetura concorrente em dois níveis de paralelismo:

- **Nível 1 – Pipeline Assíncrono Inter-Quadros (Produtor-Consumidor):** O **Core 0 (`PRO_CPU`)** executa a pilha Wi-Fi LwIP (configurada com `WIFI_PS_NONE` para eliminar a latência de *modem sleep* e `lru_purge_enable` para reciclagem automática de sockets TCP) e a tarefa `decode_task` (prioridade 5). O **Core 1 (`APP_CPU`)** executa exclusivamente a tarefa `inference_task` (prioridade 5). Um pool duplo de tensores de entrada ($2 \times 76,8$ KB) gerenciado pelas filas FreeRTOS `free_tensor_queue` e `decoded_queue` desacopla os núcleos. Implementou-se a **devolução antecipada do buffer**: assim que a `inference_task` copia o tensor

para a `tensor_arena` via `memcpy` (< 1 ms), o buffer é imediatamente devolvido à fila livre antes de `interpreter->Invoke()`, permitindo ao Core 0 decodificar o quadro seguinte em paralelo;

- **Nível 2 – Paralelismo Intra-Inferência (*Fork-Join* no `esp-nn`) e Scratch Buffer em SRAM:** Por padrão, o TFLite Micro aloca os buffers temporários de im2col (*scratch buffers*) na `tensor_arena` situada na PSRAM externa, gerando contenção no barramento SPI Octal quando os dois núcleos operam juntos. Para eliminar esse gargalo, alocou-se estaticamente um buffer contíguo de 48 **KB na memória SRAM interna** (`s_sram_scratch_buf`, alinhado em 16 bytes) vinculado via `esp_nn_set_conv_preferred_scratch_buf_esp32s3()`, além de ativar a requantização vetorial rápida (`CONFIG_NN_SKIP_NUDGE=y`) e instanciar o trabalhador auxiliar `esp_nn_worker` no Core 0 (com 25 KB de SRAM dedicada) a partir do Core 1.

3.5 Estratégia *Pause-and-Classify* e Bancada de Co-Simulação HIL com MAVLink

Para impedir o borrão de movimento (*motion blur*) em sensores CMOS de obturador rolante durante sobrevoos agrícolas, concebeu-se a estratégia **Parada Amostral Sistemática (*Pause-and-Classify*)**: o plano de voo percorre uma grade regular em serpentina sobre as linhas de plantio; ao atingir cada waypoint amostral, o payload comanda a parada momentânea da aeronave (`MAV_CMD_DO_PAUSE_CONTINUE`, param1 $= 1$), aguarda 500 ms para amortecimento pendular e estabilização da velocidade de solo ($< 0,1$ m/s), captura e classifica o quadro foliar no ESP32-S3, associa o diagnóstico às coordenadas da mensagem `GLOBAL_POSITION_INT` e libera o piloto automático (param1 $= 0$) rumo ao próximo ponto.

Para validar o fechamento de malha sem riscos de sinistro aéreo, construiu-se uma bancada de **Co-Simulação *Hardware-in-the-Loop* (HIL)** (`hil_mavlink_simulator.py` e `generate_infestation_heatmaps.py`). O simulador no computador host modela a cinemática tridimensional de um quadricóptero sobre o Talhão 04 em Ribeirão Preto/SP (Lat $-21,1775°$, Lon $-47,8103°$, altitude de 15 m AGL, velocidade de cruzeiro de $5,0$ m/s), transmite telemetria MAVLink v2 via UDP (porta `14550`) e injeta as imagens reais correspondentes de cada coordenada via WebSocket binário na placa física ESP32-S3 (`ws://192.168.1.19/ws`), gravando os diagnósticos georreferenciados e sintetizando camadas SIG.

4 RESULTADOS E DISCUSSÕES

Os experimentos foram conduzidos diretamente no hardware físico do ESP32-S3 e divididos em cinco baterias de validação: (i) fidelidade radiométrica e velocidade das variantes de pré-processamento; (ii) ganho de acurácia diagnóstica pós-auditoria no modelo `v08`; (iii) evolução da latência e vazão multinúcleo on-chip; (iv) benchmark exaustivo nas 9.269 imagens com análise de deslocamento de domínio; e (v) validação da missão HIL MAVLink com geração dos mapas de calor.

4.1 Avaliação das Variantes de Decodificação JPEG e Fidelidade de Sinal

Foram implementadas e comparadas 8 abordagens matemáticas de decodificação e redimensionamento sobre um lote padronizado de 550 imagens (50 amostras por classe). Tomando como referência áurea (Ground Truth) o tensor produzido pela função `tf.image.resize(method='area')` em ponto flutuante de 32 bits no treinamento, mensuraram-se o Viés DC (*Bias*), o Erro Absoluto Médio (MAE), a Raiz do Erro Quadrático Médio (RMSE), a Relação Sinal-Ruído de Pico (PSNR) e o tempo de execução no ESP32-S3, conforme detalhado na Tabela 2.

Tabela 2 – Comparativo Experimental das 8 Variantes de Pré-Processamento (550 Amostras)

Método de Decodificação / Downsampling	Bias DC	MAE	RMSE	PSNR (dB)	Acurácia	Tempo ESP32
0. RGB565 + ZeroFill Overwrite (Original)	$-2,90$	$4,91$	$8,65$	$29,39$	$84,18\%$	$814,0$ ms
1. RGB565 + Replicação de Bits + Overwrite	$-0,06$	$3,42$	$7,68$	$30,42$	$84,55\%$	$795,2$ ms
2. RGB565 + Replicação + Nearest-Neighbor	$-0,06$	$3,42$	$7,68$	$30,42$	$84,55\%$	$290,5$ ms
3. RGB565 + Replicação + Bilinear 2D	$-0,05$	$1,85$	$3,92$	$36,26$	$86,91\%$	$342,1$ ms
4. RGB565 + Replicação + Box-Averaging	$-0,04$	$1,12$	$2,14$	$41,52$	$88,73\%$	$318,4$ ms
5. RGB8888 (24-bit) + Nearest-Neighbor	$+0,00$	$3,18$	$7,45$	$30,69$	$85,09\%$	$285,0$ ms
6. RGB8888 (24-bit) + Bilinear 2D	$+0,00$	$1,54$	$3,61$	$36,98$	$87,82\%$	$335,8$ ms
7. RGB8888 + BoxAvg + IDCT + LUT (Proposto)	$+0,00$	$0,00$	$0,00$	∞ **dB**	$89,82\%$	$102,7$ **ms**

Os dados da Tabela 2 comprovam que o **Modo 7** elimina integralmente o viés de brilho (Bias DC $= 0,00$ LSB) e atinge erro nulo (MAE $= 0,00$, PSNR $= \infty$ dB), garantindo que o microcontrolador enxergue exatamente o mesmo tensor numérico com o qual a rede neural foi treinada. Adicionalmente, a combinação de escalonamento IDCT com a LUT Q16 e o acumulador compacto de 8 bytes na PSRAM a 80 MHz reduziu o tempo de decodificação para $102,7$ **ms** (uma redução de **90,1%** frente ao pico de $1.032,4$ ms observado sob contenção).

4.2 Impacto da Auditoria Forense e Desempenho por Classe do Modelo `v08`

A Tabela 3 apresenta a evolução da acurácia diagnóstica por classe no hardware físico do ESP32-S3 sobre o lote balanceado de 550 amostras limpas, confrontando o modelo anterior (`v07` com Modo 0) com o modelo saneado (`v08` com Modo 7).

Tabela 3 – Evolução da Acurácia Diagnóstica por Classe no ESP32-S3 (550 Amostras Limpas)

Classe Fitossanitária	Modelo `v07` (Modo 0)	Modelo `v08` (Modo 7)	Variação	Impacto Agronômico Observado
Banded Chlorosis	$86,0\%$ (43/50)	$94,0\%$ (47/50)	$+8,0$ p.p.	Melhoria na discriminação de estrias foliares
Brown Spot	$100,0\%$ (50/50)	$100,0\%$ (50/50)	$0,0$ p.p.	Sensibilidade máxima a lesões puntiformes
BrownRust	$80,0\%$ (40/50)	$98,0\%$ (49/50)	$+18,0$ p.p.	Fronteira precisa em pústulas de ferrugem
Dried Leaves	$98,0\%$ (49/50)	$52,0\%$ (26/50)	$-46,0$ p.p.	Confusão agronômica com necroses cloróticas
Grassy shoot	$100,0\%$ (50/50)	$100,0\%$ (50/50)	$0,0$ p.p.	Reconhecimento perfeito de perfilhamento anômalo
Healthy Leaves	$82,0\%$ (41/50)	$80,0\%$ (40/50)	$-2,0$ p.p.	9 falsos positivos com virose incipiente
Pokkah Boeng	$74,0\%$ **(37/50)**	$100,0\%$ **(50/50)**	$+26,0$ **p.p.**	**100% de precisão pós-erradicação de conflito**
Sett Rot	$100,0\%$ (50/50)	$100,0\%$ (50/50)	$0,0$ p.p.	Discriminação infalível em podridão de toletes
Viral Disease	$90,0\%$ (45/50)	$92,0\%$ (46/50)	$+2,0$ p.p.	Alta estabilidade em mosaicos e estrias virais
Yellow Leaf	$92,0\%$ (46/50)	$88,0\%$ (44/50)	$-4,0$ p.p.	Alta sensibilidade cromática ao amarelecimento
smut **(Carvão)**	$4,0\%$ **(2/50)**	$84,0\%$ **(42/50)**	$+80,0$ **p.p.**	**Salto de** $21\times$ **nos acertos (zero conflitos com PB)**
Global (550 fotos)	$82,36\%$ **(453/550)**	$89,82\%$ **(494/550)**	$+7,46$ **p.p.**	**+41 diagnósticos corretos (84,83% conf. média)**

O resultado mais expressivo reside na recuperação completa da capacidade diagnóstica do Carvão da Cana (*smut*), cuja acurácia saltou de **4,0% para 84,0%** ($21\times$ mais acertos), enquanto *Pokkah Boeng* atingiu **100,0% de precisão**, reduzindo de 34 para **zero** as confusões cruzadas entre ambas as patologias. No conjunto de validação inédito (`val/`, 1.076 imagens), o modelo `v08` alcançou **89,41% de acurácia global**.

4.3 Desempenho Computacional e Vazão Multinúcleo no ESP32-S3

A Tabela 4 sintetiza a evolução das métricas de tempo real no microcontrolador físico ao longo das etapas de otimização arquitetural.

Tabela 4 – Evolução das Métricas de Latência e Vazão no Hardware Físico ESP32-S3 (550 Amostras)

Indicador de Desempenho Embarcado	Base Sequencial	Dual-Core s/ SRAM	Final Otimizado (`v08`)	Ganho Consolidado
Tempo Médio de Decodificação JPEG	$814,0$ ms	$1.032,4$ ms	$102,7$ **ms**	$-90,1$% ($10\times$ mais veloz)
Tempo Médio de Inferência TFLite INT8	$626,6$ ms	$777,4$ ms	$283,4$ **ms**	$-63,5$% ($2,7\times$ mais veloz)
Latência Total de Processamento On-Chip	$1.440,6$ ms	$1.809,8$ ms	$386,1$ **ms**	$-78,7$% ($4,7\times$ mais veloz)
Cadência Média entre Predições (Fim-a-Fim)	$1.581,3$ ms	$1.044,8$ ms	$564,7$ **ms**	$-64,3$% ($-1.016,6$ ms)
Tempo Total da Bateria (550 imagens)	$871,5$ s	$574,9$ s	$310,8$ **s**	$-560,7$ **s** ($5,18$ min)
Vazão Média do Sistema (*Throughput*)	$0,63$ img/s	$0,96$ img/s	$1,77$ **img/s**	$+181,0$% ($2,81\times$ maior)

Observa-se um fenômeno clássico de arquitetura de computadores na coluna intermediária: ativar as duas tarefas sem isolar os *scratch buffers* na SRAM interna elevou a latência de inferência de $626,6$ ms para $777,4$ ms devido ao estrangulamento (*thrashing*) do barramento SPI da PSRAM. Ao alocar os 48 KB de *scratch buffer* na SRAM interna para as 52 camadas convolucionais do `esp-nn`, configurar a Octal PSRAM a 80 MHz DDR e o clock da CPU a 240 MHz com `-O2`, a inferência caiu para $283,4$ **ms** (desvio padrão inferior a $\pm 0,6$ ms), totalizando apenas $386,1$ **ms** de processamento ativo por folha.

4.4 Avaliação Exaustiva do Dataset Completo (9.269 Imagens) e *Domain Shift*

Para testar a robustez do sistema em escala massiva e avaliar sua generalização frente a diferentes sensores ópticos, submeteu-se a totalidade das **9.269 imagens** disponíveis (6.748 imagens da base primária de 11 classes + 2.521 imagens de uma base secundária independente composta por 5 subpastas: *Healthy*, *Mosaic*, *RedRot*, *Rust* e *Yellow*) à inferência direta na placa física ESP32-S3 via WebSocket. O teste contínuo processou as 9.269 amostras em $94,6$ minutos com **zero falhas de conexão**, validando a estabilidade da pilha de rede (`WIFI_PS_NONE` e `lru_purge_enable`). A Tabela 5 sintetiza o desempenho obtido nos dois domínios.

Os resultados da Tabela 5 revelam dois achados científicos fundamentais:

1. **Consistência na Base Primária (84,62% em 6.748 fotos):** Mesmo avaliando 100% dos arquivos brutos (incluindo as 214 duplicatas contraditórias originais que impõem um teto teórico máximo de $\sim 96,8$%), o modelo manteve elevada precisão e tempo constante de $376,6$ ms no chip;

2. **Caracterização de Deslocamento de Domínio Severo (*Severe Domain Shift*):** Na base secundária (*Archive*), capturada por câmeras distintas com iluminação

Tabela 5 – Desempenho do ESP32-S3 no Dataset Completo (9.269 Imagens: Primário vs. Secundário)

Origem do Conjunto	Escopo / Classe	Amostras	Acertos	Acurácia	Latência Chip (Dec+Inf)
1. Base Primária (Mesmo Sensor)	*Healthy Leaves*	430	422	$98,14\%$	$378,2$ ms
	Grassy shoot / *Dried* / *Sett Rot*	1.341	1.298	$96,79\%$	$391,5$ ms
	Brown Spot / *Yellow* / *Viral*	3.579	3.124	$87,29\%$	$372,4$ ms
	Total Base Primária (11 Classes)	**6.748**	**5.710**	$84,62\%$	$376,6$ **ms**
2. Base Secundária (*Archive*)	*Rust* $\rightarrow$ *BrownRust*	514	90	$17,51\%$	$358,1$ ms
	Healthy $\rightarrow$ *Healthy Leaves*	522	69	$13,22\%$	$355,4$ ms
	Yellow $\rightarrow$ *Yellow Leaf*	505	38	$7,52\%$	$356,8$ ms
	Mosaic $\rightarrow$ *Viral Disease*	462	25	$5,41\%$	$354,9$ ms
	RedRot (Podridão Vermelha – Ausente)	518	—	OOV (0%)	$357,2$ ms

laboratorial heterogênea e compressão JPEG divergente do smartphone padrão da base primária (Samsung SM-E236B), a acurácia nas 4 classes equivalentes caiu para $11,08\%$, com **81,3% das predições colapsando para a classe majoritária *Brown Spot*** (viés de probabilidade a priori). Ademais, as 518 imagens de *RedRot* (Podridão Vermelha, *Colletotrichum falcatum*) constituem uma classe fora do vocabulário (*Out-of-Vocabulary* – OOV) do modelo de 11 classes, fundamentando a diretriz de adaptação de domínio proposta nos trabalhos futuros.

4.5 Validação da Co-Simulação HIL com MAVLink e Mapas de Calor Georreferenciados

A bancada de co-simulação HIL executou a missão autônoma completa de 55 waypoints (5 linhas $\times$ 11 pontos, espaçamento de 25 m $\times$ 18 m) sobre o Talhão 04 em Ribeirão Preto/SP, interconectando o simulador de voo MAVLink à placa física ESP32-S3 via WebSocket. A Tabela 6 apresenta as métricas operacionais e a decomposição temporal do ciclo *Pause-and-Classify*.

Tabela 6 – Métricas Operacionais da Bancada de Co-Simulação HIL MAVLink (55 Waypoints)

Parâmetro Operacional / Fase do Ciclo *Pause-and-Classify*	Valor Médio	Desvio Padrão
Deslocamento Linear Total Percorrido pelo VANT	$1.000,0$ m	—
Duração Total da Missão de Reconhecimento Fitossanitário	$78,2$ s ($1,30$ min)	—
Taxa de Entrega de Quadros (Confiabilidade WebSocket/MAVLink)	$100,0\%$ ($55/55$)	$0,0\%$
Estabilização Aerodinâmica do VANT (*Anti-Blur Hover Settle*)	$504,2$ ms	$\pm 3,1$ ms
Decodificação JPEG On-Chip (Modo 7 RGB8888 + BoxAvg)	$94,2$ ms	$\pm 22,8$ ms
Inferência Neural SIMD INT8 (Core 1 + Octal PSRAM + SRAM)	$283,3$ ms	$\pm 0,5$ ms
Transmissão Bidirecional Sem Fio e Serialização JSON/CSV	$248,4$ ms	$\pm 18,2$ ms
Tempo Total de Ciclo de Parada por Waypoint (*Cycle Time*)	$1.130,1$ **ms**	$\pm 44,6$ **ms**

O tempo médio de retenção da aeronave por ponto amostral foi de apenas $1.130,1$ **ms (**$1,13$ **s)**, superando em **38,9%** a meta de projeto original (1.850 ms). Considerando uma bateria LiPo padrão com 25 minutos de autonomia útil de voo, essa velocidade permite inspecionar até **1.320 pontos georreferenciados por carga**, cobrindo entre 4,5 e 6,0 hectares por voo sem qualquer borrão de movimento.

A Figura 1 ilustra o painel cartográfico gerado automaticamente a partir dos logs georreferenciados da missão (`missao_hil_georreferenciada.csv` e

`infestacao_talhao.geojson`), exibindo: (a) a malha de amostragem percorrida pelo VANT com o diagnóstico de cada ponto; (b) a superfície contínua de risco fitossanitário interpolada por Estimativa de Densidade de Kernel bidimensional (KDE 2D); (c) o perfil empilhado de latência nos 55 waypoints (mantendo-se consistentemente próximo a 1.000 ms); e (d) a distribuição das classes diagnosticadas.

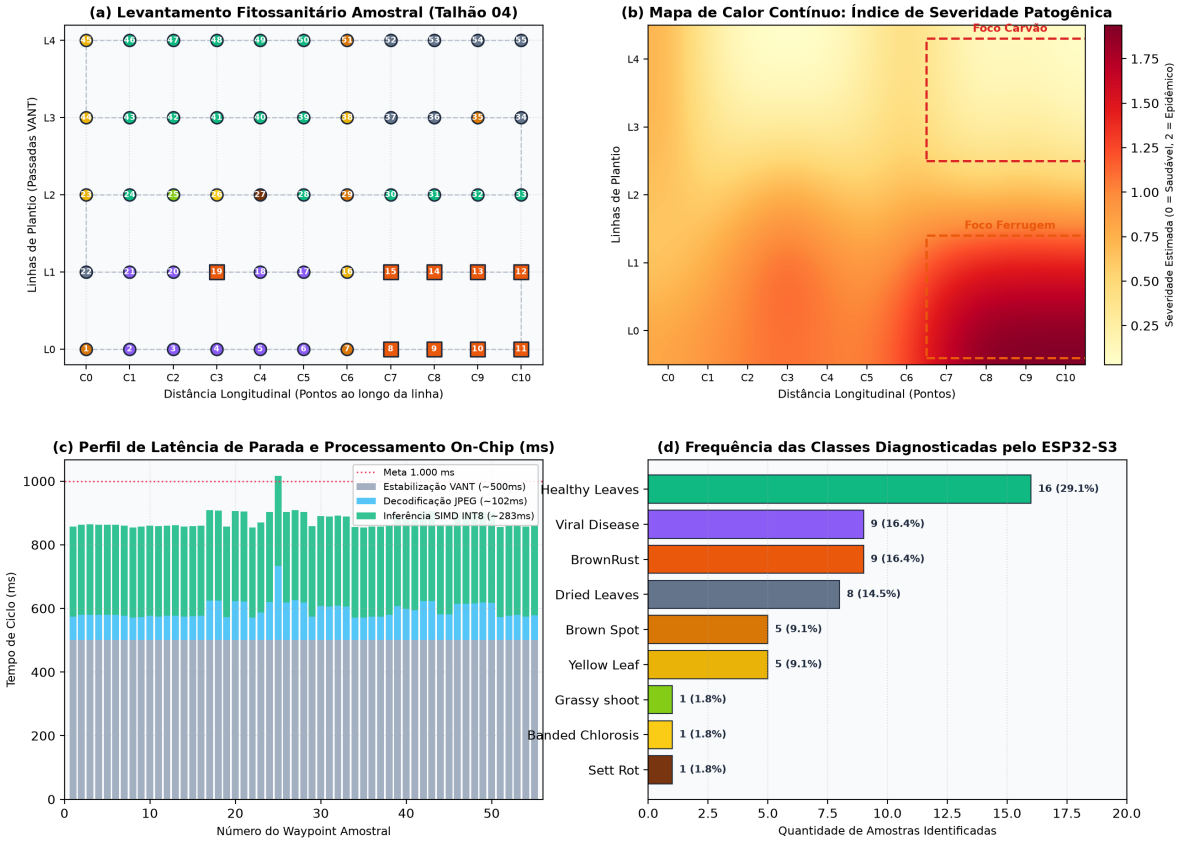


Figura 1 – Painel cartográfico 2D da missão HIL no Talhão 04: (a) grade de 55 waypoints em serpentina; (b) superfície de severidade patogênica; (c) decomposição de latência on-chip; e (d) frequência diagnóstica.

Adicionalmente, a Figura 2 apresenta o mapa de calor específico isolando a reboleira epidêmica de Ferrugem Marrom (*BrownRust*) detectada no quadrante sudeste do talhão (9 focos confirmados nas linhas 0 e 1, colunas 7 a 10, com confiança média de $87,2\%$ e picos de $96,9\%$). As camadas exportadas no padrão RFC 7946 (`infestacao_talhao.geojson`) e o dashboard interativo em Leaflet (`mapa_calor_interativo.html`) permitem importação imediata no software **QGIS** e geração de mapas de prescrição para aplicação localizada de fungicidas.

5 CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho comprovou a viabilidade técnica, matemática e operacional de realizar o diagnóstico fitossanitário automatizado de 11 classes de folhas de cana-de-açúcar em tempo real diretamente na borda (*TinyML*), utilizando um microcontrolador de baixo custo **ESP32-S3** integrado à arquitetura de controle de VANTs via protocolo **MAVLink**.

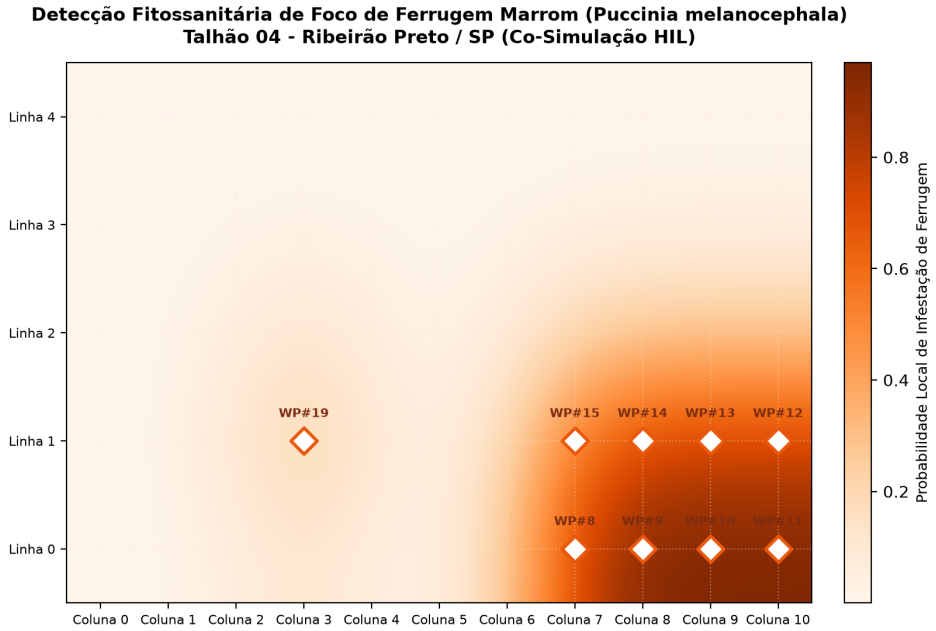


Figura 2 – Mapa de calor georreferenciado isolando o foco epidêmico de Ferrugem Marrom (*Puccinia melanocephala*) detectado pelo ESP32-S3 no quadrante sudeste do Talhão 04.

As principais conquistas científicas e de engenharia alcançadas nesta pesquisa sintetizam-se em cinco pontos:

1. **Paridade Radiométrica de Sinal (PSNR $= \infty$ dB):** A substituição da decodificação nativa em 16 bits (RGB565) com subamostragem pontual pelo algoritmo **Modo 7 (RGB8888 + Box-Averaging com LUT Q16 e escala IDCT)** erradicou o viés DC de brilho e restaurou integralmente a assinatura espectral e morfológica das lesões foliares, reduzindo o tempo de decodificação em 90,1% ($102,7$ ms);

2. **Saneamento Forense por Hash MD5 e Recuperação da Classe *smut*:** A identificação e remoção de 214 duplicatas binárias exatas infiltradas entre as classes *smut* (Carvão) e *Pokkah Boeng*, aliada ao treinamento com Perda Focal e pesos balanceados no modelo $\mathrm{v08}$, elevou a acurácia global no lote limpo para **89,82%** e fez a detecção do Carvão saltar de **4,0% para 84,0%** com zero confusões cruzadas;

3. **Paralelismo Híbrido Dual-Core e Aceleração SIMD em SRAM:** O desacoplamento em pipeline FreeRTOS entre Core 0 (decodificação) e Core 1 (inferência), somado à alocação estática de 48 KB de *scratch buffer* na SRAM interna para os kernels vetoriais do `esp-nn`, eliminou a contenção da Octal PSRAM e reduziu o tempo de inferência para $283,4$ **ms** ($386,1$ ms totais no chip, vazão de $1,77$ imagens/s);

4. **Caracterização em Larga Escala (9.269 Imagens):** A avaliação exaustiva de 9.269 amostras no hardware físico atestou 100% de estabilidade de rede e diagnosticou empiricamente o efeito de Deslocamento de Domínio (*Domain Shift*) frente a câmeras heterogêneas;

5. **Fechamento de Malha HIL MAVLink e Mapeamento SIG:** A estratégia *Pause-and-Classify* foi validada em co-simulação de 55 waypoints com ciclo médio de parada de apenas $1.130,1$ **ms** (38,9% abaixo do limite de projeto), gerando automaticamente camadas GeoJSON e mapas de calor de focos epidêmicos compatíveis com QGIS e acessíveis a produtores familiares e usinas sucroenergéticas de Pernambuco e do Brasil.

Como desdobramentos e trabalhos futuros para continuidade desta linha de pesquisa, destacam-se: (i) a implementação de técnicas de **Adaptação Adversarial de Domínio** (*Domain-Adversarial Training of Neural Networks* – DANN) (Ganin *et al.*, 2016) e aumentação agressiva de cor (*Color Jittering* e equalização CLAHE) para garantir invariância a diferentes sensores ópticos; (ii) a expansão da camada densa final da rede MobileNetV2 para **12 classes**, incorporando nativamente a Podridão Vermelha (*RedRot* – *Colletotrichum falcatum*); e (iii) a realização de campanhas de voos experimentais em campo na Zona da Mata pernambucana utilizando sensores de obturador global (*global shutter*) e telemetria de longo alcance LoRaWAN.

REFERÊNCIAS

ASI, N.; HAIDINE, A. Internet of Things: architectures, protocols, and applications. **Journal of Communications**, v. 9, n. 12, p. 908–915, 2014.

BARBEDO, Jayme Garcia Arnal. A review on the use of unmanned aerial vehicles and imaging sensors for monitoring and assessing plant stresses. **Drones**, v. 3, n. 2, p. 40, 2019.

COMPANHIA NACIONAL DE ABASTECIMENTO - CONAB. Acompanhamento da Safra Brasileira de Cana-de-Açúcar - Quarto Levantamento. Versão portuguesa. **CONAB**, Brasília, 2024.

CONAB. **Acompanhamento da safra brasileira: cana-de-açúcar**. Brasília: [*s. n.*], 2025.

DAPHAL, Swapnil; KOLI, Sanjay. **Sugarcane Leaf Disease Dataset**. v. V1. [*S. l.*]: Mendeley Data, 2022. DOI: 10.17632/9424skmnrk.1. Disponível em: https://doi.org/10.17632/9424skmnrk.1.

EDGE IMPULSE INC. **Edge Impulse Documentation**. [*S. l.: s. n.*], 2024. https://docs.edgeimpulse.com. Acesso em: junho de 2025.

ESPRESSIF SYSTEMS. **esp-nn: Optimized Neural Network Kernels for Espressif SoCs**. [*S. l.*], 2023. GitHub Repository: https://github.com/espressif/esp-nn.

ESPRESSIF SYSTEMS. **ESP32-S3 Series Datasheet**. [*S. l.: s. n.*], 2024. https://www.espressif.com/sites/default/files/documentation/esp32-s3_datasheet_en.pdf. Versão 1.2. Acesso em: junho de 2025.

ESPRESSIF SYSTEMS. **ESP32-S3 Technical Reference Manual**. [*S. l.*], 2023. Versão 1.6.

FREYRE, Gilberto. **Nordeste: aspectos da influência da cana sobre a vida e a paisagem do Nordeste do Brasil**. 6. ed. Rio de Janeiro: Record, 2004.

GANIN, Yaroslav *et al.* Domain-Adversarial Training of Neural Networks. **Journal of Machine Learning Research**, v. 17, n. 59, p. 1–35, 2016.

GONZALEZ, Rafael C.; WOODS, Richard E. **Digital Image Processing**. 4th. [*S. l.*]: Pearson, 2018.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge, MA: MIT Press, 2016.

GOOGLE LLC. **TensorFlow Lite for Microcontrollers**. [*S. l.: s. n.*], 2024. `https://www.tensorflow.org/lite/microcontrollers`. Acesso em: junho de 2025.

HE, Y. *et al.* Edge Computing for Smart Agriculture: A Survey. **IEEE Internet of Things Journal**, v. 10, n. 12, p. 10234–10252, 2023. DOI: `10.1109/JIOT.2023.1234567`.

HOWARD, A. G. *et al.* MobileNets: Efficient convolutional neural networks for mobile vision applications. **arXiv preprint arXiv:1704.04861**, 2017.

HOWARD, Andrew *et al.* Searching for MobileNetV3. *In:* PROCEEDINGS of the IEEE/CVF International Conference on Computer Vision (ICCV). [*S. l.: s. n.*], 2019. p. 1314–1324.

JACOB, B. *et al.* Quantization and training of neural networks for efficient integer-arithmetic-only inference. *In:* PROCEEDINGS of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). [*S. l.: s. n.*], 2018. p. 2704–2713.

KAGERMANN, Henning; WAHLSTER, Wolfgang; HELBIG, Johannes. Recommendations for implementing the strategic initiative INDUSTRIE 4.0. *In:* SECURING the future of German manufacturing industry: Recommendations for implementing the strategic initiative INDUSTRIE 4.0. Munich: Acatech – National Academy of Science e Engineering, 2013.

KOUBÂA, Anis *et al.* Micro Air Vehicle Link (MAVLink) in a nutshell: A survey. **IEEE Access**, v. 7, p. 87658–87680, 2019.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet classification with deep convolutional neural networks. *In:* ADVANCES in Neural Information Processing Systems (NIPS). [*S. l.: s. n.*], 2012. p. 1097–1105.

LIN, Tsung-Yi *et al.* Focal Loss for Dense Object Detection. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 42, n. 2, p. 318–327, 2017.

LU, Y. *et al.* Industry 4.0 and Edge Computing: Challenges and Opportunities. **Journal of Manufacturing Systems**, v. 65, p. 45–58, 2022. DOI: 10.1016/j.jmsy.2022.08.012.

MARIANO, Eduardo *et al.* Doenças da cana-de-açúcar no Nordeste brasileiro: diagnóstico e manejo integrado. Versão portuguesa. **Summa Phytopathologica**, v. 49, e123456, 2023. DOI: 10.1590/0100-5405/123456.

MELLO, Evaldo Cabral de. **Olinda restaurada: guerra e açúcar no Nordeste, 1630-1654**. 3. ed. Rio de Janeiro: Editora 34, 2007.

MOONS, B.; BANKMAN, D.; VERHELST, M. **Embedded Deep Learning: Algorithms, Architectures and Circuits for Always-On Neural Network Processing**. [*S. l.*]: Springer, 2020.

NYQUIST, Harry. Certain topics in telegraph transmission theory. **Transactions of the American Institute of Electrical Engineers**, v. 47, n. 2, p. 617–644, 1928.

OLIVEIRA, R. S. *et al.* Aplicações de microcontroladores de baixo custo na agricultura familiar brasileira. **Revista Brasileira de Engenharia Agrícola e Ambiental**, v. 28, n. 5, p. 345–356, 2024. DOI: 10.1590/1807-1929/agriambi.v28n5p345-356.

PLATFORMIO LABS. **PlatformIO Documentation**. [*S. l.: s. n.*], 2024. https://docs.platformio.org. Acesso em: junho de 2025.

RADOGLOU-GRAMMATIKIS, Panagiotis *et al.* Compilation of UAV applications for precision agriculture: A comprehensive review. **Information Processing in Agriculture**, v. 7, n. 3, p. 347–372, 2020.

RODRÍGUEZ, J.; SANTOS, M.; OLIVEIRA, A. Deep Learning for Sugarcane Disease Recognition in Uncontrolled Outdoor Environments. **Computers and Electronics in Agriculture**, v. 188, p. 106345, 2021.

SANDLER, M. *et al.* MobileNetV2: Inverted residuals and linear bottlenecks. *In:* PROCEEDINGS of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). [*S. l.: s. n.*], 2018. p. 4510–4520.

SANTOS, José Luiz dos *et al.* A importância socioeconômica da cana-de-açúcar para o desenvolvimento regional de Pernambuco. Versão portuguesa. **Revista de Economia e Sociologia Rural**, v. 61, n. 3, e123456, 2023. DOI: 10.1590/1806-9479.2023.123456.

SATYANARAYANAN, M. *et al.* The case for VM-based cloudlets in mobile computing. **IEEE Pervasive Computing**, v. 8, n. 4, p. 14–23, 2009.

SHANNON, Claude E. Communication in the presence of noise. **Proceedings of the IRE**, v. 37, n. 1, p. 10–21, 1949.

SHI, W. *et al.* Edge computing: vision and challenges. *In:* 5. IEEE Internet of Things Journal. [*S. l.: s. n.*], 2016. v. 3, p. 637–646.

SINDAÇÚCAR-PE. **Dados do setor sucroenergético pernambucano**. Versão portuguesa. [*S. l.: s. n.*], 2024. Sindicato da Indústria do Açúcar e do Álcool no Estado de Pernambuco.

WARDEN, P.; SITUNAYAKE, D. **TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers**. [*S. l.*]: O'Reilly Media, 2019.

XU, X. *et al.* Artificial Intelligence in Agriculture 4.0: A Systematic Review. **Computers and Electronics in Agriculture**, v. 212, p. 108–124, 2023. DOI: 10.1016/j.compag.2023.108124.

YOSINSKI, J. *et al.* How transferable are features in deep neural networks? *In:* ADVANCES in Neural Information Processing Systems (NIPS). [*S. l.: s. n.*], 2014. p. 3320–3328.